Global Solution: Segurança pública inteligente em São Paulo

Classificação de ocorrências com MLP

Disciplina: Aprendizado Profundo com Redes Neurais Convolucionais

Integrantes:

- Hanin Atwi — RM 567626
- Laura Stephanie Vasquez Oliveira — RM 567277

1 — Apresentação do projeto

Neste projeto, desenvolvemos um modelo de aprendizado profundo capaz de classificar registros de ocorrências policiais da cidade de São Paulo em duas categorias: Furto e Roubo, utilizando uma rede neural do tipo Multilayer Perceptron (MLP).

Nosso objetivo foi preparar os dados, desenvolver e comparar três arquiteturas de redes neurais, selecionar o melhor modelo com base nos resultados de validação e integrá-lo a uma aplicação web desenvolvida com Streamlit.

O sistema classifica ocorrências já registradas ou hipotéticas a partir de suas características. Não tem como objetivo prever crimes futuros ou estimar riscos de criminalidade.

2 — Problema e base de dados

Fonte: Crime Data in Brazil — Kaggle

https://www.kaggle.com/datasets/inquisitivecrow/crime-data-in-brazil

- Arquivo utilizado: `BO_2016.csv`
- Período: 2016
- Recorte aplicado: `CIDADE == "S.PAULO"`
- Registros após a limpeza: **442.672**
- Grupos únicos de boletins de ocorrência: **439.897**

Definição da variável-alvo

Utilizamos a coluna `RUBRICA` para construir a classificação binária:

Natureza da ocorrência	Classe

Furto (art. 155)	0
Furto qualificado (art. 155, §4º)	0
Roubo (art. 157)	1

Excluímos categorias ambíguas, como A.I.-Furto e A.I.-Roubo, para manter uma definição consistente das classes.

A coluna `RUBRICA` foi utilizada exclusivamente para criar a variável-alvo e não foi incluída entre os atributos de entrada.

3 — Preparação dos dados

Selecionamos cinco variáveis de entrada:

Variável	Tipo	Justificativa
`MES`	Numérica	Representa o mês da ocorrência.
`LATITUDE`	Numérica	Representa a localização geográfica.
`LONGITUDE`	Numérica	Complementa a representação geográfica.
`CONDUTA`	Categórica	Descreve o contexto da ocorrência.
`NOME_DELEGACIA_CIRC`	Categórica	Identifica a circunscrição policial associada ao registro.

Pré-processamento

- Remoção de grupos de boletins com classificações conflitantes.
- Imputação numérica pela mediana.
- Padronização numérica com StandardScaler.
- Imputação categórica pela categoria mais frequente.
- Codificação One-Hot Encoding.
- Exclusão de identificadores administrativos e variáveis com risco de vazamento.

Após o pré-processamento, obtivemos **158 características**.

Divisão dos dados

Conjunto	Registros	Proporção
Treinamento	309.868	70%
Validação	66.402	15%
Teste	66.402	15%
Total	**442.672**	**100%**

Utilizamos StratifiedGroupKFold para manter registros pertencentes ao mesmo boletim no mesmo conjunto. O pré-processador foi ajustado exclusivamente com os dados de treinamento.

4 — Arquitetura da MLP

Implementamos uma rede neural Multilayer Perceptron para classificação binária.

A estrutura utilizada possui:

- Camada de entrada com 158 características.
- Camadas ocultas densas com função de ativação ReLU.
- Camada de saída com um neurônio e ativação Sigmoid.

A camada de saída produz um valor entre 0 e 1, interpretado como a probabilidade estimada da classe Roubo.

Limiar de classificação:

- Resultado maior ou igual a 0,5: Roubo (1).

- Resultado menor que 0,5: Furto (0).

5 — Configuração do treinamento

Parâmetro	Configuração
Função de perda	Binary Crossentropy
Otimizador	Adam
Taxa de aprendizado	0,001
Batch size	512
Épocas máximas	40
Ativação das camadas ocultas	ReLU
Ativação da saída	Sigmoid
Early Stopping	Patience = 5
Restore best weights	Ativado
Semente aleatória	42

Utilizamos Early Stopping monitorando a perda de validação (`val_loss`), com restauração dos pesos da melhor época, para reduzir o risco de overfitting.

6 — Experimentos com arquiteturas

Comparamos três arquiteturas, variando a quantidade de camadas ocultas e neurônios.

Modelo	Arquitetura	Característica
MLP 1	32	Uma camada oculta, arquitetura mais simples.
MLP 2	64–32	Duas camadas ocultas, com maior capacidade.
MLP 3	128–64–32	Três camadas ocultas, arquitetura mais profunda.

Mantivemos os mesmos dados, função de ativação, otimizador, taxa de aprendizado, função de perda e hiperparâmetros para os três experimentos.

Dessa forma, a principal diferença entre os modelos foi a arquitetura das camadas ocultas.

7 — Comparação e seleção do modelo

Comparamos as três arquiteturas utilizando as métricas calculadas no conjunto de validação.

Modelo	Accuracy	Precision	Recall	F1-score
MLP 1 — 32	0.7554	0.7466	0.7146	0.7303
MLP 2 — 64–32	0.7577	0.7474	0.7207	0.7338
MLP 3 — 128–64–32	0.7599	0.7535	0.7163	0.7344

Modelo selecionado

MLP 3 — 128–64–32 neurônios

O notebook selecionou essa arquitetura como melhor modelo pelo maior F1-score na validação.

Na época 30, identificada como a melhor época pela menor perda de validação, obtivemos:

Métrica	Treinamento	Validação
Loss	0,4888	0,5005
Accuracy	76,46%	75,99%

Diferença entre os conjuntos:

- Loss: 0,0117.
- Accuracy: 0,0047.

A proximidade entre os resultados indica uma diferença pequena entre treinamento e validação.

8 — Avaliação final do modelo

Após selecionar a arquitetura MLP 3, realizamos a avaliação final utilizando o conjunto de teste, que não participou do treinamento ou da seleção do modelo.

Métricas do conjunto de teste

Métrica	Resultado
Accuracy	0.7594
Precision	0.7519
Recall	0.7161
F1-score	0.7336

ROC-AUC	0.8346
Log Loss	0.5015

Matriz de confusão

Inserir a matriz de confusão gerada pela célula 20 do notebook.

A matriz permite analisar:

- Verdadeiros positivos: roubos classificados corretamente.
- Verdadeiros negativos: furtos classificados corretamente.
- Falsos positivos: furtos classificados incorretamente como roubos.
- Falsos negativos: roubos classificados incorretamente como furtos.

Curvas de aprendizado

Inserir:

- Gráfico de acurácia de treinamento e validação.
- Gráfico de perda de treinamento e validação.

As curvas permitem avaliar a evolução do aprendizado e identificar possíveis sinais de overfitting ou underfitting.

9 — Aplicação web

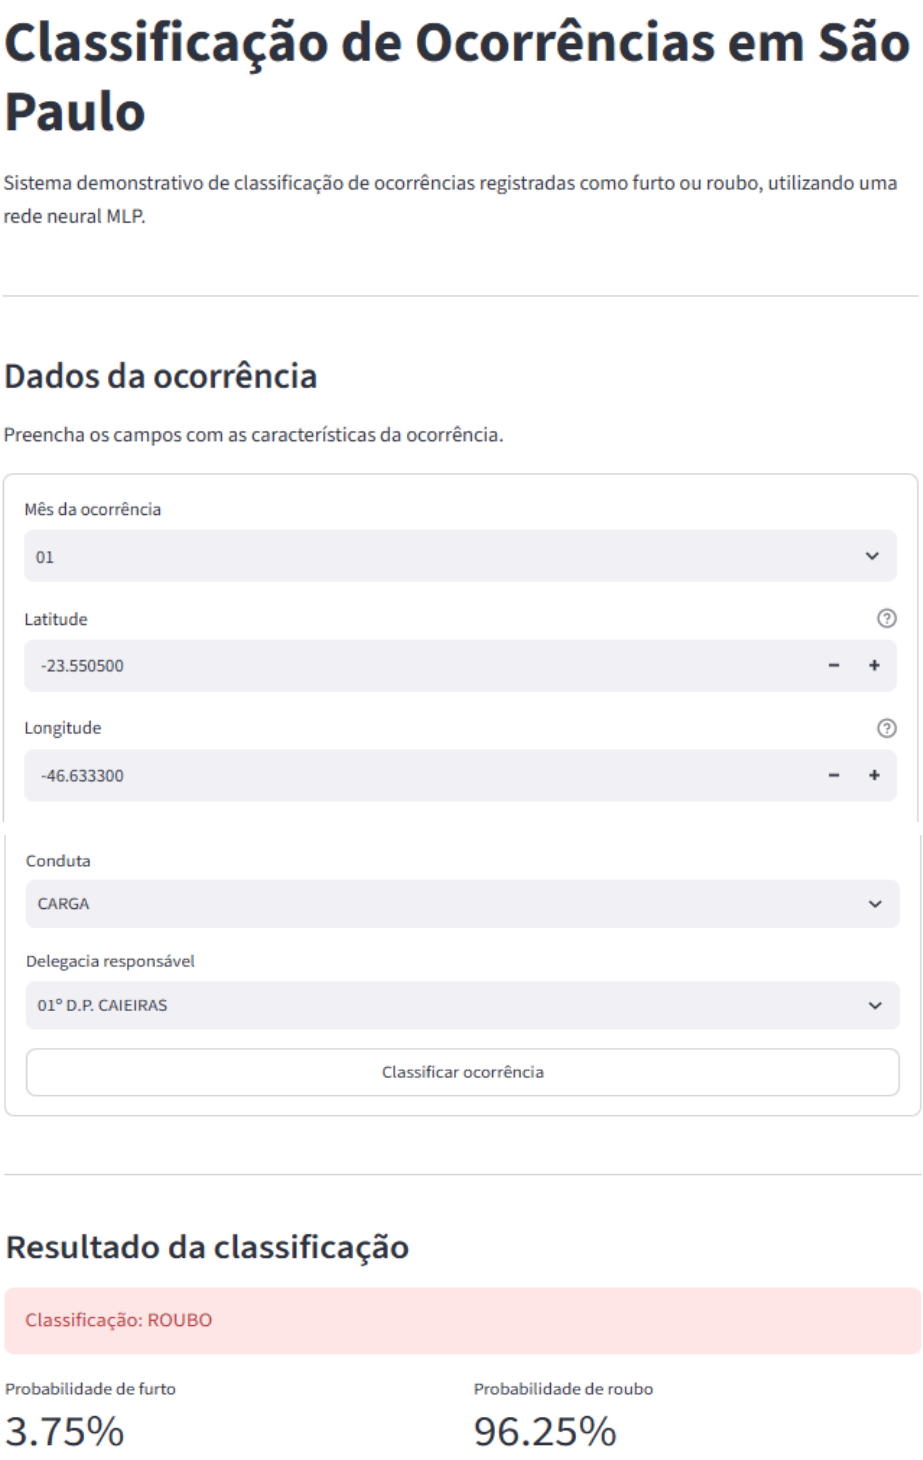
Desenvolvemos uma aplicação web utilizando Streamlit, integrada ao modelo MLP selecionado e ao pré-processador dos dados.

A aplicação permite informar:

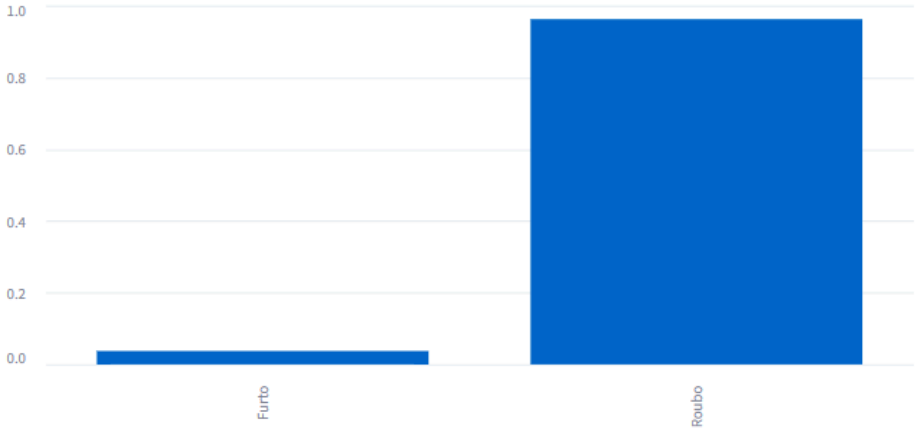
- Mês da ocorrência.
- Latitude.
- Longitude.
- Conduta.
- Delegacia responsável.

Após o envio do formulário, o sistema apresenta a classificação estimada entre Furto e Roubo e as probabilidades atribuídas a cada classe.

Captura de tela:



Distribuição das probabilidades:



A classificação utiliza o limiar de decisão de 0,5, conforme a configuração do modelo.

Projeto acadêmico desenvolvido para a FIAP. O modelo classifica registros de ocorrências como furto ou roubo com base nos dados fornecidos. Ele não prevê crimes futuros, não identifica suspeitos e não estima o risco criminal de pessoas ou regiões.

Dados da ocorrência

Preencha os campos com as características da ocorrência.

Mês da ocorrência

03

Latitude

-20.000000

Longitude

46.633300

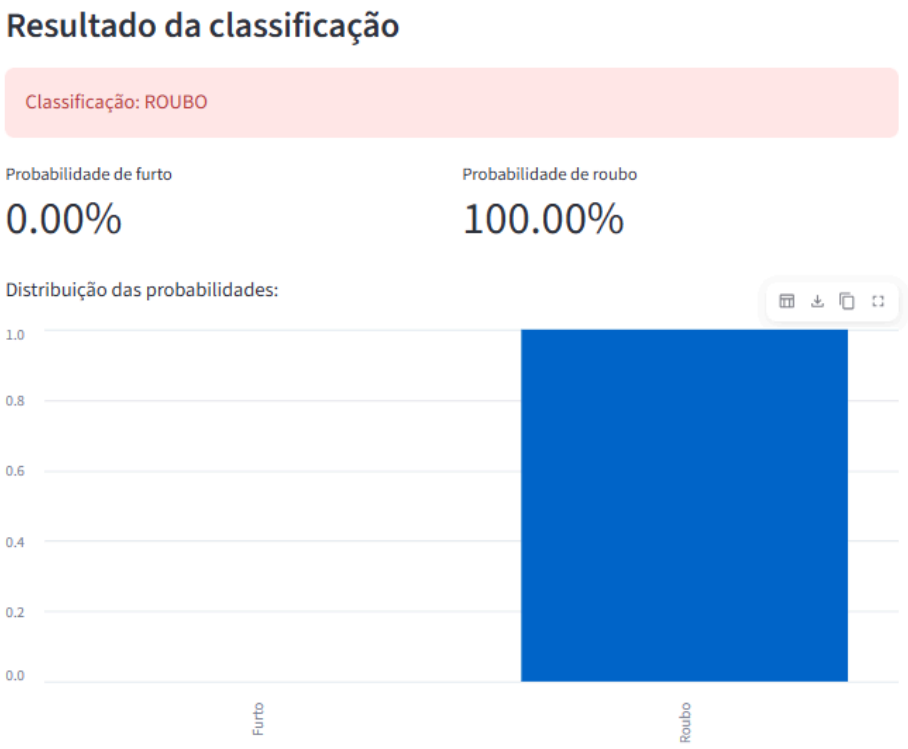
Conduta

Caixa Eletrônico

Delegacia responsável

01º D.P. MAUA

Classificar ocorrência



Link da aplicação: Local URL: http://localhost:8502

Network URL: http://172.16.1.208:8502

10 — Conclusões, limitações e uso de IA

Conclusões

Desenvolvemos um fluxo completo de classificação binária utilizando redes neurais MLP, incluindo preparação dos dados, comparação de três arquiteturas, seleção baseada em validação e integração do modelo a uma aplicação web.

A arquitetura selecionada foi a MLP 3 (128–64–32), com base no F1-score de validação.

A avaliação final no conjunto de teste permite analisar a capacidade de classificação do modelo em registros não utilizados nas etapas anteriores.

Limitações

- A base contém registros referentes somente ao ano de 2016.
- A classificação depende da qualidade e das informações disponíveis nos boletins.
- As categorias representam a natureza registrada no boletim, não necessariamente uma conclusão judicial.

- Os resultados não podem ser generalizados automaticamente para outros anos ou contextos.
- O modelo não prevê crimes futuros, não identifica suspeitos e não estima o risco criminal de pessoas ou regiões.

Utilização de inteligência artificial generativa

Utilizamos ferramentas de inteligência artificial generativa para auxiliar na identificação de erros, revisar códigos e organizar a documentação.